

# Instituto Politécnico de Beja

Sistema de apoio à promoção do turismo rural Fase de Análise de Texto via Machine Learning

> Gonçalo Amaro – 17440, Pedro Tomás – 18962, Vítor Abreu – 18966

XX de Janeiro, 2022

# Conteúdo

1	Introdução	3
2		3
	2.1 Extração de Palavras Chave	3
	2.1.1 Processo de Execução	3
	2.1.2 Processo de Desenvolvimento	4
	2.2 Análise de Sentimento	4
	2.2.1 Processo de Execução	4
	2.2.2 Processo de Desenvolvimento	4
3	Itesutuaes	4
	3.1 Extração de Palavras Chave	4
	3.2 Análise de Sentimento	4
4	Conclusão	4
5	Webgrafia	4

# 1 Introdução

Após descrito os fundamentos de ETL e uma vez que a fase de estamos atualmente é a de transformação será necessário ser usado um tipo de processos bastante conhecido chamado de "extração de palavras chave" e "análise de sentimentos". Estes processos consistem:

- retirar do texto as palavras mais importantes que sejam capazes de descrever o estabelecimento.
- caracterizar o sentimento do texto, ou seja, saber se o texto é positivo ou negativo.

#### 2 Análise de Texto

Uma Análise de Texto é um processo de extração de palavras chave e análise de sentimento. Basicamente os processos acima descritos. Mais especificamente a extração de palavras chave é feita através de um algoritmo de Machine Learning que é chamado de "bag of words" ou "bag of features"; e a análise de sentimento é feita através de um algoritmo de Machine Learning que é chamado de "Naive Bayes" ou "Naive Bayes Classifier", ou usando "transformers" ou "transformer" que é um algoritmo de Machine Learning que é chamado de "Tf-Idf" ou "Term Frequency - Inverse Document Frequency".

O ultimo caso foi descrito com duas opções porque como poderão verificar mais à frente, a nossa tentativa de "Naive Bayes" não foi bem sucedida, e por isso foi usado um "transformer" com um dataset chamado de "Bert" ou "Bert For Classification", este foi criado pela "Google".

Para a realização dos processos acima descritos usaremos a linguagem de programação "Python" e variadas bibliotecas. Das quais:

- nltk Natural Language Toolkit.
- sklearn Scikit-learn.
- numpy Numpy.
- pandas Pandas.
- transformers Transformers.
- torch PyTorch.
- yake YAKE!.

Será feita a realização de um script por cada processo, que será transformado num notebook, via p2j, para que possa ser documentado.

#### 2.1 Extração de Palavras Chave

Aqui foi executado o processo de extração de palavras chave, que consistiu em usar o YAKE!, que é uma biblioteca de autores portugueses e um japonês que foi criada para extrair palavras chave de um texto. Os seus autores são residentes em: Instituto Politécnico de Tomar, Universidade da Beira Interior, Universidade do Porto, INESC TEC e Universidade de Kyoto.

A razão especifica do uso desta biblioteca ao invés de fazer de raiz, foi o facto acima descrito, em nome de apoio ao uso de trabalhos de autoria portuguesa.

#### 2.1.1 Processo de Execução

Este "script" funciona da seguinte forma:

- Indicamos o caminho da pasta onde se encontra o texto a ser analisado.
- Importa todos os .csv de reviews que se encontram na pasta.
- Por cada .csv de reviews, extrai as palavras chave.
- Exporta as palavras chave para um .csv.

#### 2.1.2 Processo de Desenvolvimento

## 2.2 Análise de Sentimento

#### 2.2.1 Processo de Execução

Este "script" funciona da seguinte forma:

- Indicamos o caminho da pasta onde se encontra o texto a ser analisado.
- Importa todos os .csv de reviews que se encontram na pasta.
- Por cada .csv de reviews, faz a análise de sentimento.
- Exporta os sentimentos para um .csv.

#### 2.2.2 Processo de Desenvolvimento

## 3 Resultados

- 3.1 Extração de Palavras Chave
- 3.2 Análise de Sentimento
- 4 Conclusão
- 5 Webgrafia